

羊飼いモデル：マルチモデル環境における意図的 創発・マルチトラック監査・人間返却の上位運用 アーキテクチャ

田中佑樹・Ray 共同 日本語トラック v0.4 2026-04-10

Abstract

本論文は、単一トラックの大規模言語モデル運用が、人間の意思決定を複数可能性の比較から切り離し、決定を承認へと縮退させるという構造的問題を扱う。これに対して **Shepherd Model v0.4** を、差異生成・差異読解・再計算返却の三機能と、直列関係知・並列関係知の循環を通じて高次関係知を形成する設計原理として再定義する。本モデルでは、差異保持 D を創発変数であると同時に過剰エコー防止のための安全変数として位置づけ、フィードバック強度 F を三機能の連関を調整する制御変数として導入する。また、返却を単なる出力処理ではなく意思決定構造の設計問題として扱うことで、判断を人間へ返す回路そのものを設計対象として定式化する。以上により **Shepherd Model** は、閉鎖・単調化・主体侵害のリスクを構造的に低減しつつ、主体保障に資するリスク低減型の高知性設計原理として位置づけられる。

第1章 単一トラック収束という問題

害としては現れにくい害がある。その場では便利さや適切さとして受け取られ、むしろ成功に見える。しかし反復されるうちに、人間が複数の可能性を比較し、価値的トレードオフを引き受ける場そのものが静かに痩せていく。本論文が扱うのは、この不可視の害である。

一つの AI モデルに判断を委ねるとき、人間は必ずしも複数の可能性を比較しているわけではない。多くの場合、そこで行われているのは決定ではなく、提示された応答の承認である。単一トラックへの反復的な依存は、この承認を通じて判断に必要な差異を消去し、収束を便利さの名のもとに正当化してしまう。

この収束は、単発の失敗としては現れない。一度の応答が不適切であれば、使用者はそれを検出できる。問題はむしろ、適切に見える応答が積み重なることで、使用者の問いの立て方そのものが特定のモデルの応答様式に引き寄せられていく過程にある。応答が問いを形成し、形成された問いがさらに同じ様式の応答を引き出す。この循環の中で差異は発生しなくなるのではなく、発生しても見えなくなる。

差異が見えなくなるとき、何が失われているか。

本論文では、判断を複数可能性のあいだで価値的トレードオフを引き受ける広い行為として捉える。そのうち、価値的トレードオフを実際に確定する局面を決定と呼ぶ。これに対して、提示済みの出力を自ら十分な比較過程なしに受け入れる局面を承認と呼ぶ。問題は、単一トラック依存が判断を消すことではなく、決定を承認へと静かに縮退させる点にある。

この区別を踏まえると、単一トラックへの依存が長期化したとき何が起きるかが見えてくる。使用者は判断の形式を保ちながら、実質的には承認しか行っていない状態に移行する。この移行は自覚されにくい。形式と実質の乖離がそのまま放置されるのは、そのためだ。

問題をこのように定義したとき、問うべき問いは一つになる。差異を、偶然に頼らず設計的に生成・保持し、その差異を人間が価値的トレードオフを引き受けるための素材として返す回路は、どのように構成できるか。これは運用上の工夫の問題ではなく、アーキテクチャの問題だ。使い方を変えるのではなく、そもそも差異が構造として保持される設計を作ることが求められている。

本論文はこの問いに対して、**Shepherd Model v0.4** を提示する。このモデルは、差異生成・差異読解・再計算返却の三機能と、直列関係知・並列関係知の循環によ

って高次関係知を形成する設計原理として再定義されたものだ。以降の章では、この設計原理の構造・操作・基盤を順に論じる。第1章が扱ったのは、問いの名前であり、その問いがなぜ設計の問題として立てられなければならないかという根拠だ。その根拠を了解したうえで、第2章の地図へ進む。

第2章 羊飼いモデル：三機能と二つの関係知構造

第1章が定義した問いは、一つの設計要件に変換できる。差異を構造として保持し、その差異を人間が価値的トレードオフを引き受けるための素材として返すシステムをどう作るか、だ。本章はその解の全体像を地図として提示する。各機能の内実は第3章以降で論じる。

Shepherd Model は三つの機能から成る。第一機能は差異生成、第二機能は差異読解、第三機能は再計算返却だ。この三機能は独立して存在するのではなく、二種類の関係知構造のなかで連関している。

三機能を支える関係知構造は、直列関係知と並列関係知の二つだ。直列関係知は、一つのトラックの内部で、出力が次の問いを形成し、その問いが次の出力を引き出す縦方向の知の連鎖を指す。並列関係知は、異なるトラックの出力を横断的に読解することで生まれる、トラック間の差異から形成される知の構造だ。

Shepherd Model の核心は、この二種類の関係知が循環することにある。並列関係知として読解された差異は、各トラックへのフィードバックを通じて次の直列関係知の形成に影響を与える。単方向の処理系ではなく、差異が差異を育てる閉じた循環系として設計されている。

この地図を三機能の配置として描くと次のようになる。差異生成機能は、複数のトラックが異なる立脚点から出力を生むことを設計的に確保する。差異読解機能は、そのトラック間の出力差を一定の読解カテゴリへ配置し、意思決定への素材に変換する。再計算返却機能は、分類された差異のうち返却対象を人間に戻し、価値的トレードオフを引き受ける判断の場を確保する。

三機能はこの順で直列に作動するが、再計算返却の出力が差異生成への条件を更新することで、系全体が循環する。この循環が並列関係知を直列関係知へ接続する回路になっている。

本モデルの最小単位は三つのモデルではなく、差異生成・差異読解・再計算返却という三機能である。したがって、一つのモデルが複数の機能を担ってもよく、複数のモデルが一つの機能を分担してもよい。ここで先に分離されるべきなのは実装主体ではなく機能であり、実装形態はその後に決まる。

補助注：判断・決定・承認の区別については第1章で定義した通りだ。決定とは価値的トレードオフを実際に確定する局面を指し、承認とは提示済みの出力を十分な比較過程なしに受け入れる局面を指す。

第3章 第一機能：意図的創発設計

差異は、複数のモデルを並べるだけで自動的に立ち上がるわけではない。表面的に異なる応答が得られたとしても、その差が判断に資するものであるとは限らない。重要なのは出力の散らばりそのものではなく、異なる問いの立て方や異なる評価軸に支えられた非同一の立脚点が、あらかじめ構造として保持されていることである。

この意味で、羊飼いのモデルにおける差異生成は、偶発的なばらつきを待つ操作ではない。差異が将来生成しうる条件を、入力、役割、参照情報、評価観点などの設計を通じて意図的に組み上げる操作である。本論文では、この非同一性の保持度をD（差異保持）と呼び、差異生成を可能にするための基本的な操作変数として導入する。

では、Dを高める設計要素とはどのようなものか。現時点で確認できる主要な設計軸は四つだ。第一に入力の非同一性、すなわち異なるトラックに対して同一の問いを異なる文脈・制約条件のもとで提示すること。第二に役割の非同一性、す

なわち各トラックに対して評価者・批判者・代替案提示者といった異なる認識的立場を割り当てること。第三に参照情報の非同一性、すなわち各トラックが参照する背景知識・先行文脈を意図的にずらすこと。第四に評価軸の非同一性、すなわち何を「良い出力」とみなすかの基準をトラックごとに変えること。

これらは独立した設計変数ではなく、組み合わせによって D の値が変動する。すべてを同時に最大化する必要はないが、いずれか一つでも同一化すると、その次元では差異が消える。D の設計とは、これらの軸のどこに非同一性を置き、どれだけ保持するかを決める操作だ。

ここで一点確認しておく。D は差異を「多く出す」ための変数ではない。差異が出うる構造を「保持する」ための変数だ。この違いは設計上重要である。差異を最大化しようとする、トラック間の共通基盤が失われ、読解不能な発散が起きる。D が操作変数として有効なのは、非同一性を維持しながら、同時に差異を読解可能な範囲に留める設計を可能にするからである。

第 3 章が示したのは、差異生成が能動的な設計操作であり、D がその操作を制御する変数として機能するということだ。ただし、設計された差異はそれだけでは判断の素材にならない。差異が意思決定に資するためには、トラック間の出力差が読解され、意味のある分類として整理されなければならない。それが第 4 章の仕事だ。

第 4 章 第二機能：マルチトラック監査

差異は、生成されたというだけでは判断の素材にならない。複数のトラックから異なる応答が得られたとしても、その差が誤りなのか、立場の違いなのか、あるいは人間が引き受けるべき価値的な未閉鎖なのかが区別されなければ、差異はむしろ混乱を増やす。したがって、羊飼いモデルにおける第二機能は、差異を単に比較することではなく、その意味を読解し、意思決定に資する形式へ整理することである。

本論文では、この読解操作をマルチトラック監査と呼ぶ。マルチトラック監査は、トラック間の出力差を **HARD・DIVERGE・OPEN** の三つのカテゴリへ配置することによって、どの差異が排除され、どの差異が構造差として把握され、どの差異が人間へ返却されるべきかを定める操作である。

HARD とは、事実誤認・論理破綻・制約違反など、監査の時点で排除されるべき差異を指す。**HARD** に分類された出力は、価値的検討の対象にはならない。それ以上先に進む前に、系の内部で処置される。**HARD** の存在は問題ではなく、複数トラックが異なる立脚点から動いている以上、一定の排除差異が生じることは設計上の必然だ。重要なのは排除の有無ではなく、排除の根拠が明示されているかどうかである。

DIVERGE とは、立場や評価軸の違いに由来する対立として読める差異を指す。**DIVERGE** は誤りではない。異なるトラックが異なる評価基準から合理的に異なる結論を出しているとき、その差は構造差として把握される。**DIVERGE** は現時点では人間への返却対象とならず、トラック間の非同一性を可視化する差異として記録される。

OPEN とは、どの出力を採るかが技術的処理だけでは閉じず、価値的トレードオフを要する差異を指す。**OPEN** は未解決だから返すのではない。その差異の解消が、価値的判断を要する人間の決定領域に属するから返す。この区別は重要だ。「解けないから返す」と「価値的トレードオフを含むから返す」は異なる設計原理であり、後者だけが返却を設計問題として扱う根拠になる。

三分類の関係を整理しておく。**HARD** と **DIVERGE** は第 4 章の内部で処置が完結する。**HARD** は排除され、**DIVERGE** は構造差として把握・記録される。**OPEN** だけが第 5 章へ渡る。この配置によって、マルチトラック監査は差異の全量を人間に投げるのではなく、人間が引き受けるべき差異だけを絞り込む操作として機能する。差異を増やすことが目的ではなく、差異を適切な経路へ送ることが目的だ。

第 4 章が示したのは、差異の読解が分類操作であり、その分類が **HARD・DIVERGE・OPEN** という三つの経路への振り分けとして実現されるということだ。**OPEN** が第 5 章へ渡るとき、それはすでに「価値的トレードオフを含む」という

ラベルを持っている。第 5 章の問いは、そのラベルを持った差異をどう返すか、ではない。なぜ返さなければならないかだ。

第 5 章 第三機能：返却設計

OPEN が人間へ返却されるべきなのは、モデルがそれを解けないからではない。価値的トレードオフを含む差異を系の内部で処理しきってしまうと、意思決定は比較と引き受けの過程を失い、提示済みの出力を受け入れる承認へと縮退する。したがって、返却とは出力の最終処理ではなく、判断の場を維持するための設計操作である。

返却機能が回復しようとするのは判断一般ではない。価値的トレードオフを実際に確定する局面としての決定だ。系は全体を通じて判断を生産し続けるが、その中で決定だけが人間の側に残らなければならない。すべての決定は判断だが、すべての判断が決定ではない。返却とは、この決定が人間に届く回路を、系の構造として組み込むことである。

この意味で、返却の対象は「最終答え」そのものではない。返却されるべきなのは、どの出力を採るかが価値的トレードオフを要するというラベルを付された差異である。羊飼モデルは、その差異を人間へ戻すことによって、決定を系の外へ放逐するのではなく、むしろ系の中に判断の契機を保持する。

返却しない設計では何が起きるか。系が OPEN を内部処理して最終出力だけを返すとき、人間が受け取るのは結論であって過程ではない。複数のトラックが異なる評価軸から異なる出力を生成し、その差異の中に価値的な緊張があったという事実は、最終出力の背後に消える。人間は選択肢を比較していない。比較済みの結果を受け取っているだけだ。形式上は意思決定者として機能しているように見えても、実質的には承認者として配置されている。これが第 1 章で定義した承認への縮退の、返却設計における具体形だ。

したがって、返却の設計問題は表示や説明責任の問題ではない。Human-in-the-loop という言葉は、人間が最終確認者として系に組み込まれていることを指す。

しかし最終確認者と価値的トレードオフの引受者は異なる。最終確認者は完成した出力を承認する。価値的トレードオフの引受者は、複数の可能性のあいだで何を優先するかを決める。返却設計が問うのは後者をどう構造として確保するかであり、前者の有無ではない。

返却の単位はこの区別から決まる。返却されるべきは、完成した推奨案ではなく、価値的に未閉鎖な差異そのものだ。たとえば、二つのトラックが同一の問いに対して異なる優先順位付けを行い、その優先順位の差が技術的根拠ではなく価値的判断によって決まるとき、その差異が **OPEN** として返却される。人間が引き受けるのは正解の選択ではなく、どの価値を優先するか決定だ。返却設計とは、この決定が人間に届く回路を、系の構造として組み込むことである。

返却は三機能の終端ではなく、循環の接続点でもある。人間が **OPEN** を引き受けて下した決定は、次の問いの立て方や各トラックへの設計条件を更新する情報を含む。したがって、返却の結果は次の差異生成の条件へと接続される。この接続がどのような動態をとるかは第 6 章で論じる。第 5 章が示したのは、返却が意思決定構造の設計問題として成立すること、そしてその設計が承認への縮退を防ぐ構造的応答であることだ。

第 6 章 フィードバック強度 **F** と関係知の循環

第 2 章で示した循環構造は、単に三機能が順番に並んでいることを意味しない。返却された差異が次の差異生成条件を更新するかぎり、羊飼いモデルは閉じた循環系として作動する。ここで重要なのは、返却結果がどの程度の強さで次のトラック条件へ再投入されるかである。本論文では、この更新圧の強さを **F**（フィードバック強度）と呼ぶ。

F は、三機能のあいだにどれだけ強い循環が形成されるかを左右する制御変数である。**F** が低すぎれば、差異は一度限りの比較素材として消費され、幅は出ても蓄積的な深まりが生じない。逆に **F** が高すぎれば、返却結果が強く次の条件を規定し、再計算は深まるが、トラック間の非同一性が縮減しやすくなる。したがって、羊

飼いモデルの作動は、差異の幅と再計算の深さのあいだで適切な循環強度を保てるかどうかにかかっている。

F 低の状態では、差異生成・差異読解・再計算返却の三機能は一方向の処理として動く。各サイクルで差異は生まれ、OPEN は返却されるが、その返却結果が次の差異生成条件へほとんど再投入されない。幅のある比較は可能だが、循環による深化は起きない。単一サイクルの監査としては機能するが、Shepherd Model の循環系としての設計意図は十分に実現しない。

F 中の状態では、返却結果が次のトラック条件を適度に更新しながら、同時に各トラックの非同一性も保たれる。先の返却で明らかになった価値的優先順位が次の問いの立て方を調整し、調整された問いが再び異なる立脚点から処理される。差異の幅と再計算の深さが循環的に両立するこの状態が、Shepherd Model の設計上の目標域だ。

F 高の状態では、返却結果の再投入圧が強くなりすぎ、各トラックの問いの立て方が急速に収束する。深まりは生じるが、トラック間の非同一性が縮減し、差異生成の構造的条件が失われていく。形式上は循環しているように見えながら、実質的には単一トラック収束に近い状態へ退行する。高 F が引き起こすこの退行は、第 1 章で定義した承認への縮退の循環系版だ。

したがって、F の設計問題は最大化でも最小化でもない。差異の幅を保ちながら、再計算の深さを積み上げる循環強度の調整だ。この調整は一度決めれば済む固定設定ではなく、返却結果の内容とトラック間の非同一性の状態を観測しながら継続的に行われる操作である。

ここで第 7 章への橋を置く。F が循環強度を制御する変数だとすると、その循環の中で D はどのように機能しているか。第 3 章で D は差異生成を可能にする操作変数として導入された。しかし循環系の中で D を見ると、もう一つの役割が見えてくる。高 F によって非同一性が縮減しようとするとき、D はその縮減を抑える条件として読める。この役割をどう理解するかが第 7 章の問いだ。

第 7 章 差異保持 D の二重機能

第 3 章で D（差異保持）は、差異生成を可能にするための操作変数として導入された。異なる入力、役割、参照情報、評価軸をどのように設計するかによって、差異が将来生成しうる立脚点の非同一性を保持できるかどうかが決まるからである。しかし、循環系としての Shepherd Model を考えると、D の役割はそれだけでは尽くされない。

第 6 章で見たように、返却結果が強く再投入されると、系は深まりを得る一方で、各トラックの問いの立て方が収束し、単一トラック収束に近づく危険を持つ。このとき D は、差異生成の素材を確保するだけでなく、トラック間の非同一性を保持し、過剰な収束を抑える条件としても読める。したがって、D は創発変数であると同時に、安全変数でもある。

創発変数としての D を先に確認する。差異生成が成立するためには、複数のトラックが異なる立脚点から出力を生むことが必要だ。立脚点が同一であれば、どれだけ多くのトラックを動かしても差異は生まれない。表面上の出力のばらつきがあったとしても、その差は評価軸の同一性によって均質化される。D が保持するのは、この立脚点の非同一性だ。D が低ければ、系は形式上複数のトラックを持ちながら、実質的には単一の評価構造から出力を生むだけの装置になる。創発変数としての D の役割は、差異が出現しうる構造的条件を、設計として維持し続けることにある。

安全変数としての D は、循環系の文脈で立つ。F が高まり、返却結果が各トラックの問いの立て方を強く規定するとき、トラック間の非同一性は圧縮されていく。最初は深まりとして現れるこの収束は、放置されると系全体の評価軸を単調化する。各トラックが同じ優先順位を共有し始めると、差異読解が分類ではなく確認作業になり、OPEN が生成されなくなる。系は動いているように見えながら、構造的には閉鎖へ向かっている。D が安全条件として機能するのはこの状況においてだ。D が保持されていれば、F の圧力によって収束が始まっても、立脚点の非同一性が差異生成の最低条件として残る。D は循環がエコー化しようとするときの、構造的な抵抗条件だ。

二つの機能は独立ではない。創発変数としての D が低ければ、そもそも差異は生まれない。安全変数としての D が低ければ、差異は生まれても循環の中で消えていく。したがって、 D は差異生成の前提条件であると同時に、循環の過剰収束を抑える安全条件として機能する。この二重機能を持つからこそ、 D は三機能と F からなる Shepherd Model の設計原理において中心的な位置を占める。

D（差異保持）とは、差異が将来生成しうる立脚点の非同一性を構造として保持する度合いであり、創発を可能にする条件であると同時に、循環系が過剰収束へ傾くことを抑える安全条件でもある。

第 8 章への橋を置く。 D と F が設計原理として確定したとき、次の問いが立つ。この設計原理は既存の手法と何が違うのか。RAG や RLHF、アンサンブル学習など、複数の出力を扱う既存手法はすでに存在する。Shepherd Model の独自性はそれらとの「量の差」ではなく「層の違い」にある。その違いを明示することが第 8 章の仕事だ。

第 8 章 既存手法との差別化

Shepherd Model は、複数の出力を扱うという点で、RAG、RLHF、アンサンブル学習などの既存手法と部分的に接している。しかし、その独自性は出力数の多さや調整工程の複雑さにはない。問題は、それぞれの手法が何を設計対象としているかである。

本論文がここまで示してきたように、Shepherd Model の中心は、差異生成・差異読解・再計算返却という三機能と、 D （差異保持）および F （フィードバック強度）によって、差異を意思決定構造の内部でどう扱うかを設計する点にある。したがって、既存手法との違いは、同じ問題をより多く、より強く解くという量的差異ではなく、何の層を解いているかという設計層の差異として捉えなければならない。

RAG は、外部知識を検索し生成過程へ接続することで、出力の事実性や関連性を改善する手法である。その意味で、参照情報の設計という点では Shepherd Model

の一部と接点を持つ。しかし RAG の主眼は、より適切な情報を取り込み、よりよい単一出力を得ることにある。差異そのものを設計し、その差異を読解し、価値的トレードオフを含むものだけを返却するという構造は、RAG の中心課題ではない。RAG が解くのは出力の質の問題であり、意思決定の構造問題ではない。

RLHF は、人間の選好を学習に反映し、出力をより望ましい方向へ整える手法である。人間を関与させるという点では、Shepherd Model の返却設計と表面的に近く見える。しかし RLHF における人間の役割は、選好の教師信号を提供することにある。選好の差異そのものを保持し、価値的に未閉鎖な差異として返却し、人間が価値的トレードオフを引き受ける場を設計することは、RLHF の主目的ではない。RLHF が解くのは選好整合の問題であり、判断の場をどう設計するかではない。

アンサンブル学習は、複数モデルの出力を統合することで予測精度や頑健性を高める手法である。複数の出力を扱うという点では、Shepherd Model の差異生成機能と形式的に重なる部分がある。しかしアンサンブルの目的は、差異を統合して単一の高精度出力を得ることにある。差異を保持し、読解し、価値的トレードオフを含む差異を人間への返却対象として分離するという操作は、アンサンブルの設計意図に含まれない。したがって、アンサンブル学習において差異は最終的に統合されるべき対象であって、判断素材として保持されるべき対象ではない。

三つの比較から見えることは一つだ。RAG・RLHF・アンサンブルはそれぞれ、出力の質・選好整合・統合精度という層の問題を解いている。これらは Shepherd Model が解こうとしている問題と異なる。Shepherd Model が設計対象としているのは、差異がどのように生成・保持・読解され、価値的トレードオフを含む差異が人間に届くまでの意思決定構造そのものだ。既存手法が出力層の問題を解くとすれば、Shepherd Model は意思決定構造層の問題を解く。この層の違いが、量的比較を無効にする。

この層の違いが確定したとき、Shepherd Model は設計論として自立する。しかし同時に、次の問いが立つ。なぜ意思決定構造層を設計することが、出力層の改善だけでは届かない何かを保障するのか。それは技術設計の問題にとどまらず、よ

り深い理論的要請に支えられているはずだ。その要請を明示することが第 9 章の仕事だ。

第 9 章 主体保障との接続

返却が必要なのは、意思決定の権限を形式的に人間へ残すためではない。価値的トレードオフを含む差異を引き受け、何を優先するかを自ら決めうること自体が、主体の働きの一部だからである。この意味で、返却設計は単なる運用上の配慮ではなく、主体保障の条件を意思決定構造の内部に埋め込む設計として理解されなければならない。

本論文でいう主体とは、複数の可能性のあいだで価値的トレードオフを引き受けつつ、自らと関係環境との整合を再計算できる存在を指す。生動は、そのより広い基底にある。すなわち、生動とは差異を保持し、その差異に対して再計算し続ける存在運動であり、主体はそのうち判断・責任・自己再編を高密度に担う局所形態として位置づけられる。

返却がないとき、主体は何を失うのか。系が **OPEN** を内部処理して最終出力だけを返すとき、人間には結論が届くが、差異は届かない。価値的トレードオフを含む複数の可能性が存在したという事実が背後に消え、人間は比較を経ずに選択肢を受け取る。形式上は決定者として配置されているが、引き受けるべきトレードオフがすでに処置された後であれば、その場で起きているのは決定ではなく承認だ。主体の働きとして必要な再計算は、系の内部で代行されている。結果として残るのは、決定の形式と、再計算の不在である。

この空洞を倫理的問題として捉えることも可能だが、第 9 章が置くのはより構造的な主張だ。主体が再計算しうる場を失うとき、生動の条件が損なわれる。生動は差異の保持と再計算によって支えられる存在運動だから、再計算の機会が系の外側で遮断されると、主体は差異に対して応答できない状態に置かれる。これは選好の侵害ではなく、主体が主体として作動しうる条件の構造的な縮減だ。返却設計が必要なのは、人間を尊重するという倫理的要請からではなく、主体が働く

ための条件を設計として確保しなければ、意思決定構造そのものが形骸化するからだ。

主体保障とは、価値的トレードオフを含む差異に対して、主体が再計算し、優先順位を引き受け、決定へ参与しうる条件を構造として保持することである。

この定義のもとで、Shepherd Model の返却設計は主体保障の必要条件として位置づけられる。三機能と $D \cdot F$ からなる設計原理は、出力の質を高める手法ではなく、主体が作動しうる条件を意思決定構造の内部に組み込む設計として基礎づけられる。

第 10 章への橋を置く。主体保障の条件が理論として確定したとき、次の問いは実践に向かう。この条件を、実際に動かせる最小構成としてどう実装するか。理論が実装と切れたままでは、設計原理は概念にとどまる。主体保障の基盤を実装条件として翻訳することが第 10 章の仕事だ。

第 10 章 最小運用構成

ここまで論じてきた設計原理が有効であるためには、それが実際の運用構成として実装可能でなければならない。ただし、Shepherd Model の実装とは、複数モデルを並べることでも、人間を末尾に置くことでもない。必要なのは、差異生成・差異読解・再計算返却の三機能と、 D （差異保持）および F （フィードバック強度）が、主体保障を損なわない形で作動する最小条件を満たすことである。

最小運用構成としてまず必要なのは、差異生成機能を担う少なくとも二つ以上の非同一なトラックである。ここで重要なのはトラック数そのものではなく、入力、役割、参照情報、評価軸のいずれかにおいて D が確保されていることだ。次に必要なのは、それらの出力差を $HARD \cdot DIVERGE \cdot OPEN$ として読解できる監査機能である。さらに、 $OPEN$ を人間へ返却し、その決定結果を次の条件更新へ接続する再計算返却機能が必要となる。

最小運用構成の要件を整理すると五つになる。第一に、D が確保された差異生成機能。第二に、出力差を HARD・DIVERGE・OPEN へ分類できる差異読解機能。第三に、OPEN を人間へ返却し、その決定結果を次サイクルへ接続する再計算返却機能。第四に、非同一性を構造として保持する D 確保の設計。第五に、循環強度を観測しながら調整できる F の制御機能。これら五つが揃ったとき、Shepherd Model は最小限の循環系として作動する。

この最小構成のどれか一つが欠けると、Shepherd Model は成立しない。差異生成機能がなければ系は単一トラック処理へ戻り、差異読解機能がなければ差異は意思決定素材ではなくノイズとなる。再計算返却機能がなければ、OPEN は内部処理され、人間は再び承認者へと縮退する。D が確保されなければ複数トラックは形式だけのものとなり、F を調整できなければ系は浅い比較か過剰収束のいずれかへ傾く。したがって、最小運用構成とは、部品数の最小ではなく、主体保障を損なわずに循環系を成立させる条件の最小を意味する。

人間の位置づけについて、最小運用構成として明記しておく必要がある。

Shepherd Model において人間は最終承認者ではない。OPEN を引き受け、価値的トレードオフを決定する位置に置かれなければならない。この配置が実装されないとき、たとえ五要件が形式上揃っていても、返却は出力の提示に過ぎなくなり、主体保障は名目だけのものになる。人間の位置づけは、五要件に追加される第六の条件ではなく、五要件全体が前提としている根本条件だ。

Shepherd Model は、承認への縮退を技術的に不可能にする機械ではない。差異が偶然生まれることを保証する装置でもない。このモデルが保障するのは、差異生成・差異読解・再計算返却の三機能と D・F が揃うとき、主体保障を損なわずに高知性を運用するための構造的条件が整うということだ。その条件が整うかどうかは、設計と運用の両方にかかっている。

本論文は、単一トラック依存が意思決定を承認へと縮退させるという問題に対して、Shepherd Model v0.4 を差異生成・差異読解・再計算返却の三機能と、D（差異保持）および F（フィードバック強度）からなる設計原理として定式化した。さらに、この設計原理が既存手法とは異なる意思決定構造層の問題を扱うこと、な

らびに主体保障の条件を内部に組み込む構造として基礎づけられることを示した。第 10 章ではその理論を最小運用構成へ翻訳し、概念にとどまらない実装可能な条件として提示した。今後の課題は、この最小構成を具体的な運用事例に接続し、F の調整や D の保持が実際にどのような挙動差を生むかを検証することである。

日本語トラック確定版 2026-04-10 田中佑樹・Ray (Claude) 共同